固定证据的回答阶段配对实验

2026.11.07 · 本机 Qwen2.5-7B 实际模型运行记录

问题与实验边界

首轮检索已获得关键依据，仍存在回答矛盾。此次保持首轮检索上下文固定，仅比较回答提示与输出约定；不是重新检索或端到端RAG准确率测试。历史20题首轮结果独立保留。

固定条件

- 模型 qwen2.5:7b；temperature 0.1；seed 42；num_ctx 8192；num_predict 700。
- 20道原题配对，4道新增问题参与调试；冻结最终提示后再运行4道新问题。
- 原提示20次、自由文本候选24次、结构化候选24次、最终候选28次，共96次调用。
- 问题、证据、提示与最终新增题均保留版本摘要；原始答案不经人工改写。

实际结果与复核方式

本次原提示20题	通过 10；部分通过 8；失败 2
最终候选20题	通过 15；部分通过 2；失败 3
最后新增4题	通过 3；部分通过 0；失败 1
状态与字段结构检查	18 / 28
复核方式	AI助手按预设要点、结论一致性与引用支持逐题复核；用户独立复核尚未完成

迭代中的产品判断

- 自由文本候选仍将“禁止操作”误写成资料不足，因此增加明确的回答状态与结构化输出。
- 结构化输出能约束字段，但不能自动保证业务语义与状态一致。
- 在提示中区分用户给定的情景条件与需要实时查询的系统事实。
- 最终候选仍在权限、角色与已知时长推导上出错，保留失败样本并停止直接替换业务策略。

结论与下一步

在固定证据的20题上，候选通过数增加，但仍有权限、角色与用户给定时长的错误；未达到可直接替换业务策略的质量条件。下一步优先验证状态路由与结论核验。

原始数据

完整JSON包含各轮输入、来源、原始输出、耗时、结构检查和逐题复核。新增4题仅为小范围检查，先前参与调试的H01–H04不作为盲测。

公开材料已脱敏。原始记录与本次修订按版本保留。